

# AC-SAC：基於注意力機制與課程學習強化的深度強化學習社交導航

提升複雜社交場景下的機器人導航成功率



Group 10

郭乃文 (7114093001)

方芯芸 (7114064002)

李宗穆 (7114093009)

林奇和 (7114064165)




# 緒論：社交導航的典範轉移

## 過去：單純避障



## 現在：社交合規決策



## 核心痛點

服務型機器人步入公共場所（餐廳、機場），導航任務需同時兼顧安全性、效率與人類社交規範。

## 資料支撐與領域成熟度


已累積 **4,427** 條軌跡與 **4,402** 筆人工評分樣本，全面進入系統化訓練與嚴謹比較階段。

## 學習式導航的突破潛力

基準測試顯示，在擁擠場景中，優秀的學習式導航具備提升 **38.3%** 成功率與 **46%** 社交合規性的潛力。




# 緒論：現有系統的兩大瓶頸



## 瓶頸一：機器人凍結 (Freezing Robot)

傳統基於規則的演算法在密集動態人群中過於保守，頻繁找不到可行解，導致機器人停滯或任務超時。




## 瓶頸二：學習陷阱 (Learning Trap)

深度強化學習 (DRL) 在處理高維度動態特徵時，極易在訓練初期掉入局部最佳解，導致收斂困難與泛化性低。



# 相關研究：導航技術流派演進


**流派一：基於規則之模型**  
(Rule-based, e.g., ORCA, SFM)



**優點：**運算效率高，數學嚴謹。

**致命缺點：**過度假設行人完美合作。擁擠場景極易觸發「機器人凍結」。


**流派二：標準深度強化學習**  
(Standard DRL, e.g., Vanilla SAC)



**優點：**端對端訓練，無模型限制，增強避障彈性。

**致命缺點：**暴力拼接 (Flatten) 高維行人資訊會破壞空間「置換不變性」，導致 Reward 稀疏且極易掉入學習陷阱。

**流派三：單一注意力機制**  
(Single Attention, e.g., SARL)



**優點：**解決特徵提取問題。

**致命缺點：**缺乏階段性訓練引導，面對複雜動態環境，收斂速度依然極慢。



# 相關研究：技術維度綜合對比

|                         | 處理動態高維特徵 | 避免局部最佳解 | 軌跡平滑與連續控制 | 收斂速度 |
|-------------------------|----------|---------|-----------|------|
| Rule-based Models       | ✗        | ✗       | —         | ✓    |
| Standard DRL            | —        | ✗       | —         | —    |
| Single Attention (SARL) | ✓        | —       | ✓         | ✗    |
| AC-SAC (Proposed)       | ✓        | ✓       | ✓         | ✓    |

**核心結論：**整合注意力機制 (Attention) 與課程學習 (Curriculum Learning) 的 SAC 架構，能全面突破現有技術的天花板。




# 系統方法：MDP 基礎問題定義






# 系統方法：AC-SAC 核心架構圖





# 系統方法：兩大核心機制突破


## 1. 找出關鍵行人 (Attention Mechanism)



機制：動態計算周圍每個行人對機器人的**相對重要性**。

成效：賦予潛在碰撞風險較高的目標**更大權重**，徹底解決**高維度**與**數量變動狀態**的處理難題。

## 2. 穩定訓練收斂 (Curriculum Learning)



機制：透過 Reward Shaping 與**階梯式難度設計**，從簡單場景（靜態/少量行人）開始，逐步提升環境中的行人密度。

成效：提供**更密集的訓練回饋** (Denser feedback)，有效避開盲目探索導致的**學習陷阱**，確保策略穩健收斂。



# 實驗設置與評估指標

## 測試環境設置 (Environment)



分別在 5人、10人、15人、30人 的動態人群導航環境 (Crowd navigation environment) 中進行壓力測試。



測試條件：每個模型評估 100 個 Episodes。

## 消融實驗比較基準 (Ablation Baselines)



**SAC**：標準 Soft Actor-Critic。



**A-SAC**：僅加入 Attention 機制的 SAC。



**AC-SAC**：本文提出的完整架構 (Attention + Curriculum Learning)。

## 評估指標 (Evaluation Metrics)



**Success rate**  
(成功率)



**Collision rate**  
(碰撞率)



**Timeout rate**  
(超時率)



**Avg path length**  
(平均路徑長度)



**Avg reward**  
(平均獎勵)



# 實驗結果：不同密度場景考驗 (5/10/15人)

## Human = 5

| Model  | 成功率 | 碰撞率  | 超時率  | 平均長度  | 平均獎勵  |
|--------|-----|------|------|-------|-------|
| SAC    | 0%  | 0.59 | 0.41 | 0     | -0.43 |
| A-SAC  | 97% | 0.03 | 0    | 10.00 | 0.94  |
| AC-SAC | 98% | 0.02 | 0    | 11.23 | 0.94  |

## Human = 10

| Model  | 成功率 | 碰撞率  | 超時率  | 平均長度  | 平均獎勵  |
|--------|-----|------|------|-------|-------|
| SAC    | 0%  | 0.89 | 0.11 | 0     | -0.53 |
| A-SAC  | 89% | 0.11 | 0    | 11.29 | 0.80  |
| AC-SAC | 93% | 0.07 | 0    | 12.17 | 0.85  |







## Human = 15

| Model  | 成功率 | 碰撞率  | 平均長度  | 平均獎勵  |
|--------|-----|------|-------|-------|
| SAC    | 0%  | 0.59 | 0.41  | -0.43 |
| A-SAC  | 71% | 0.29 | 12.53 | 0.51  |
| AC-SAC | 92% | 0.08 | 13.31 | 0.82  |

基礎 SAC 練不起來，是因為其預設的 MLP 架構無法從高維且未結構化的人群狀態中提取出「空間拓撲」與「威脅優先級」，導致模型被龐大的無效雜訊淹沒而無法收斂。









# 5人場景的訓練畫面











# 10人場景的訓練畫面







# 15 人場景的訓練畫面





# AC-SAC在30人場景的訓練畫面





# 總結：重新定義複雜場景導航

**精準特徵  
(Attention)：**  
成功將變動數量的高  
維狀態壓縮，破解「  
空間置換」限制。

**平滑決策  
(SAC)：**  
最大熵核心確保連續  
控制的穩定性，消滅  
「機器人凍結」。

**穩定收斂  
(Curriculum)：**  
階梯式排程提供密  
集回饋，徹底避開  
「學習陷阱」。

**+ 38.3%**  
**導航成功率提升**

**+ 46.0%**  
**社交合規性提升**

AC-SAC 展現了將資料驅動與進階強化學習結合的強大實證價值，在高度複雜的真實社交場景中，重新定義了機器人導航的安全性與效率。