

提升複雜社交場景導航性能之 AC-SAC 技術架構方案

Model

提升複雜社交場景導航性能之 AC-SAC 技術架構方案

提升複雜社交場景導航性能之 AC-SAC 技術架構方案

1. 引言：社交導航的範式轉移與研發背景

隨著服務型機器人深度嵌入機場、大型商場、醫院及政務大廳等公共空間，「導航」的定義正經歷從單純「物理避障」到「社交合規決策（Socially Compliant Decision-making）」的關鍵轉移。在這些高度動態且充滿不確定性的人群環境中，機器人必須在保障絕對安全性的前提下，兼顧任務效率並遵循人類社交規範（如社交距離、路權尊重）。

根據基準測試數據，相較於傳統模型，採用「學習式導航」架構可使**導航成功率提升 38.3%**，且在**社交合規性指標上顯著提升 46%**。本方案之開發核心基於強大的數據支撐：通過對 **4,427 條導航軌跡**與 **4,402 筆人工評分樣本**的深度挖掘，我們建立了從「規則定義」轉向「行為學習」的研發體系。這種轉變不僅是算法的更迭，更是機器人進入非結構化公共空間的戰略門檻。

然而，現有系統在面對高密度人群（如每 100 平方米超過 15 人）時，普遍面臨決策僵化或策略失效的瓶頸。

2. 現有技術瓶頸與痛點剖析

在開發高級感知與運動規劃框架時，傳統算法與標準學習模型存在明顯的侷限性：

* **「機器人凍結 (Freezing Robot)」現象：

* 基於規則的模型（如 ORCA, SFM）過度依賴幾何運算與理想化的運動學假設。在密集人群中，由於規則過於保守，系統往往因判定「無碰撞解」不存在而導致機器人原地停滯或頻繁觸發超時。

* **「學習陷阱 (Learning Trap)」與收斂發散：

* 標準深度強化學習 (DRL) 在處理高維動態特徵時，極易在訓練初期掉入「局部最佳解」或 U 型性能陷阱。當行人數量增加，環境的隨機性會導致策略網路難以收斂，甚至出現嚴重的性能退化。

為量化各技術流派的戰略價值，下表對比了本方案與主流技術的關鍵維度：

技術維度	基於規則模型 (Rule-based)	標準 DRL (Vanilla SAC)	單一注意力模型 (SARL)	**AC-SAC (本方案)**
處理動態高維特徵	✗ (難以建模複雜交互)	— (暴力拼接損壞空間特徵)	✓ (特徵提取優異)	✓ (動態權重計算)
避免局部最佳解	✗ (規則邊界僵化)	✗ (易掉入 U 型陷阱)	— (缺乏引導)	✓ (課程學習引導)
軌跡平滑/連續控制	— (需 PID/MPC 轉換)	— (輸出抖動明顯)	✗ (環境複雜即發散)	✓ (最大熵連續控制)
收斂速度與穩定性	✓ (無需訓練)	— (隨環境規模發散)	✗ (缺乏階段性引導)	✓ (由簡入深快速收斂)

3. AC-SAC 系統架構設計：MDP 基礎問題定義

本方案將社交導航定義為一個優化的馬可夫決策過程 (MDP)，旨在解決傳統架構無法處理「變動行人數量」與「特徵壓縮」的技術缺陷：

* **狀態空間 S ：** 整合機器人本體狀態（座標 p , 速度 v , 目標 g ）與動態行人觀測。透過注意力機制處理數量變動的高維特徵，打破狀態輸入的維度限制。* **動作空間 A ：** 採用**連續控制輸出**，直接映射為線速度 v 與角速度 ω 。相較於離散動作，這能顯著提升運動平滑度，確保社交環境下的舒適感。* **獎勵函數 R ：** 為了誘導社交合規行為，我們設計了包含「社交距離（Discomfort penalty）」與「方向誘導」的稠密獎勵公式：

$$R_t = \{10, \text{ if } p_t = g \text{ (抵达目标)} - 0.25, \text{ if } d_t < d_{min} \text{ (发生碰撞)} - 0.0025, \text{ step penalty (时间惩罚)} csim(\frac{gv_t \cdot v_{t+1}}{|gv_t||v_{t+1}|})\}, \text{ otherwise}$$

其中包含社交不適懲罰項，確保機器人主動避開人類舒適半徑。* **轉移機率 P ：** 基於 Model-free 框架，機器人無需顯式建模行人物理模型，而是透過大規模交互學習人群的隨機動態規律。

4. 核心技術模組：注意力機制、獎勵塑造與課程學習

AC-SAC 框架的核心價值在於以下三大模組的深度協同：

4.1 注意力權重 (AW) 網絡

傳統網路將行人資訊「暴力拼接 (Flatten)」，會損壞空間置換不變性。AW 網絡通過「Attention Lens」動態計算周圍行人對機器人的相對重要性（權重），將變動數量的行人狀態壓縮為固定維度的「碰撞風險特徵向量（Collision Risk Feature Vector）」。這確保了計算資源始終聚焦於最具威脅的交互個體。

4.2 最大熵 SAC 核心

本方案採用 Soft Actor-Critic 作為底層算法，透過最大化期望獎勵與策略熵（Entropy），強化機器人在面對未知人群轉移機率 P 時的探索多樣性。這不僅提升了魯棒性，更確保了輸出的動作 A 具備高度的連續性與穩定性。

4.3 課程學習 (Curriculum Learning) 排程器

為突破「學習陷阱」，我們引入階段性訓練排程：從簡單場景（Human=5）逐步過渡至中等（Human=10）及高密度場景（Human=15/30）。這種「由簡入深」的難度曲線，使機器人能先掌握基礎導航能力，再優化複雜避障邏輯，極大提升了收斂效率。

4.4 獎勵塑造 (Reward Shaping)

引入餘弦相似度 ($csim$) 引導項，為機器人提供方向性的即時回饋。公式中的方向一致性獎勵有效減少了無效探索，使路徑規劃更符合社交效率預期。

5. 多場景實驗驗證與消融實驗分析

本方案在 Square Crossing 仿真環境下，針對 5、10、15 及 30 名行人密度進行了 100 回合的嚴格評估。

5.1 性能趨勢對比 (Ablation Study)

數據顯示，隨著行人密度增加，課程學習對穩定性的貢獻愈發關鍵：

場景：Human = 5 (基礎複雜度)

演算法	成功率	碰撞率	超時率	平均路徑長度	平均獎勵
SAC	0	0.59	0.41	0	-0.43
A-SAC (僅注意力)	0.97	0.03	0	10.0	0.94
AC-SAC (本方案)	**0.98**	**0.02**	**0**	11.23	**0.94**

場景：Human = 10 (中等密度)

演算法	成功率	碰撞率	超時率	平均路徑長度	平均獎勵
SAC	0	0.89	0.11	0	-0.53
A-SAC (僅注意力)	0.97	0.03	0	10.0	0.94
AC-SAC (本方案)	**0.98**	**0.02**	**0**	11.23	**0.94**

演算法	成功率	碰撞率	超時率	平均路徑長度	平均獎勵
A-SAC (僅注意力)	0.89	0.11	0	11.29	0.80
AC-SAC (本方案)	**0.93**	**0.07**	**0**	12.17	**0.85**

場景：Human = 15 (高密度擁擠)

演算法	成功率	碰撞率	超時率	平均路徑長度	平均獎勵
SAC	0	0.59	0.41	0	-0.43
A-SAC (僅注意力)	0.71	0.29	0	12.53	0.51
AC-SAC (本方案)	**0.92**	**0.08**	**0**	13.31	**0.82**

5.2 數據深度解讀 (The "So What?" Layer)

* **注意力機制的空間預判力**：視覺化軌跡分析顯示，在 $T = 0$ 時刻，標準 SAC 對 Human 1-5 的權重分配為無意義的 **0.00**；反觀 AC-SAC，其 AW 網絡能精確鎖定碰撞半徑內的行人（例如給予 **Human 1 權重 0.99**）。這證明了本方案具備強大的「關鍵特徵提取能力」，是避免機器人凍結的物理基礎。* **課程學習的魯棒性增益**：當人數增加至 15 人時，缺乏引導的 A-SAC 成功率驟降至 0.71，且碰撞率顯著上升；而 AC-SAC 仍維持 **0.92** 的高水準。這證明「階段性任務拆解」能有效防範模型在複雜特徵下的過擬合與發散。* **運算效率與實時性**：AW 網絡將變動輸入壓縮為固定維度，這不僅降低了推理階段的計算開銷，更保證了在嵌入式平台（如 NVIDIA Jetson Orin）上的推論實時性。

6. 結論與研發建議

AC-SAC 技術架構方案成功克服了傳統導航在社交環境中的僵化缺陷，通過「注意力機制優化特徵提取」與「課程學習穩定訓練過程」，在極端擁擠的人群中展現了卓越的自主性。

架構師建議：

- 嵌入式部署與優化**：鑑於 AW 網絡生成的固定維度特徵，建議在量產階段採用 TensorRT 進行網絡加速，以最大化其在移動底盤上的實時反應能力。
- 極限環境演進**：針對 30 人以上（極端擁擠）的場景，應持續微調課程學習的難度遞增曲線，並在獎勵函數中適度增加「Discomfort penalty」的比重，以平衡效率與社交舒適度。
- 安全冗餘設計**：雖深度學習模型已達 92% 成功率，但在最終產品化時，仍建議保留基於運動學的底層干預層，作為應對傳感器故障或模型長尾效應的安全冗餘。

本方案為服務機器人提供了具備「空間意識」與「社交溫度」的規劃核心，是提升產品在高端商務空間競爭力的戰略基石。